Regressão Sicor

June 23, 2025

1 Introdução

Dados importados da matriz de microdados do crédito rural do Sicor para o ano de 2024. O volume é grande e este documento apresenta uma tentativa experimental de usar estes dados em uma regressão linear para entender que tipo de fatores influenciam o volume de crédito tomado. Grande parte dos dados é categórica, mas ainda alguns dados são quantitativos e podem ser usados para montar uma regressão. Primeiramente, uma análise exploratória dos dados é feita. Alguns outliers são removidos usando as técnicas apresentadas no livro An Introduction to Statistical Learning para diminuir alguns problemas potenciais de pontos que possuem valores muito extremos. Os resultados da regressão dão um bom R^2 e bons testes de significância estatística. Apesar disso, ainda há indícios de heteroscedasticidade e não normalidade nos erros da regressão. Os resultados são apresentados na tabela a seguir:

Variável	Coeficiente	p-valor	Significativo a 5%
Área Financiada	2277.1065	0.000	Sim
Receita Esperada	0.2549	0.000	Sim
Quantidade produzida	0.0318	0.006	Sim
Recurso Próprio	0.1228	0.046	Sim
Juros	2885.4042	0.000	Sim

Algumas questões podem ser apontadas: 1. O coeficiente positivo para a taxa de juros pode significar que volumes de crédito maiores sendo tomados implicam em mais riscos e, portanto, maiores taxas de juros. 2. O coeficiente para a área financiada pode simplesmente significar que uma área maior implica em uma produção maior e, portanto, em mais crédito que precisa ser tomado. 3. O teste de Jarque-Bera deu estatisticamente significativo, o que dá indícios de que os erros não seguem uma distribuição normal. 4. O teste de Breusch-Pagan deu estatisticamente significativo, o que indica que o erro é heteroscedastico.

Um modelo usando apenas os dados de receita bruta esperada é tentado por último e oferece resultados bons, apesar de ter os mesmos problemas no termo erro.

Referências:

An Introduction to Statistical Learning

Dados

2 Importando os Pacotes e os dados

[1]:
```
import pandas as pd
import seaborn as sns
import statsmodels.api as sm
import numpy as np
import matplotlib.pyplot as plt
```

[2]:
```
df = pd.read_csv(r"C:\Users\joaop\Documents\Dados de Conjuntura\Dados␣
↪SICOR\Tabelas\DADOS_2024.csv")

df.shape
```

[2]:
```
(2510518, 60)
```

[3]:
```
# head do dataframe

df.head()
```

[3]:
```
   REF_BACEN  NU_ORDEM   CNPJ_IF  DT_EMISSAO DT_VENCIMENTO  CD_INST_CREDITO  \
0  516467660         1  92816560  08/01/2024    15/08/2033                5
1  517254551         1    360305  02/01/2024    21/12/2025                1
2  517254553         1         0  02/01/2024    29/12/2024               10
3  517254555         1         0  02/01/2024    19/12/2024               10
4  517254557         1         0  02/01/2024    13/12/2024               10

   CD_CATEG_EMITENTE  CD_FONTE_RECURSO  CNPJ_AGENTE_INVEST CD_ESTADO  …  \
0               3333               403                 NaN        PR  …
1               2222               201                 NaN        PA  …
2               2222               431                 NaN        MG  …
3               2222               431                 NaN        GO  …
4               2222               300                 NaN        RO  …

     ATIVIDADE                                    MODALIDADE  \
0  Pecuário(a)  MÁQUINAS, EQUIPAMENTOS, MATERIAIS E UTENSÍLIOS
1  Pecuário(a)              AQUISIÇÃO E MANUTENÇÃO DE ANIMAIS
2  Pecuário(a)                                   BOVINOCULTURA
3  Pecuário(a)                                   BOVINOCULTURA
4  Pecuário(a)                                   BOVINOCULTURA

            PRODUTO                                          VARIEDADE  \
0  GRANJAS AVÍCOLAS  ABRANGE A COMPRA DE EQUIPAMENTO NECESSÁRIO A S…
1           BOVINOS                                     NÃO SE APLICA
2           BOVINOS                                             LEITE
3           BOVINOS                                             LEITE
4           BOVINOS                                             LEITE
```

```
                                DESCRICAO_FONTES  \
0                      RECURSOS LIVRES EQUALIZÁVEIS
1                           OBRIGATÓRIOS - MCR 6.2
2  LETRA DE CRÉDITO DO AGRONEGÓCIO (LCA) - CONTRO…
3  LETRA DE CRÉDITO DO AGRONEGÓCIO (LCA) - CONTRO…
4  POUPANÇA RURAL - CONTROLADOS - SUBVENÇÃO ECONÔ…

                                DESCRICAO_PROGRAMA  \
0  MODERAGRO - PROGRAMA DE MODERNIZAÇÃO DA AGRICU…
1  PRONAF - PROGRAMA NACIONAL DE FORTALECIMENTO D…
2  PRONAF - PROGRAMA NACIONAL DE FORTALECIMENTO D…
3  PRONAF - PROGRAMA NACIONAL DE FORTALECIMENTO D…
4  PRONAF - PROGRAMA NACIONAL DE FORTALECIMENTO D…

                              DESCRICAO_SUBPROGRAMA  DESCRICAO_AGRO  \
0  Fomentação Prod Benef Industr Acond Armaz (MCR…   Não se aplica
1                                Custeio (MCR 10-4)   Não se aplica
2                                Custeio (MCR 10-4)   Não se aplica
3                                Custeio (MCR 10-4)   Não se aplica
4                                Custeio (MCR 10-4)   Não se aplica

   DESCRICAO_CULTIVO  DESCRICAO_INTEGRACAO
0      Não se aplica         Não se aplica
1      Não se aplica         Não se aplica
2      Não se aplica         Não se aplica
3      Não se aplica         Não se aplica
4      Não se aplica         Não se aplica

[5 rows x 60 columns]
```

[4]:
```
# olhando as variáveis

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2510518 entries, 0 to 2510517
Data columns (total 60 columns):
 #   Column                    Dtype
---  ------                    -----
 0   REF_BACEN                 int64
 1   NU_ORDEM                  int64
 2   CNPJ_IF                   int64
 3   DT_EMISSAO                object
 4   DT_VENCIMENTO             object
 5   CD_INST_CREDITO           int64
 6   CD_CATEG_EMITENTE         int64
 7   CD_FONTE_RECURSO          int64
 8   CNPJ_AGENTE_INVEST        float64
```

```
9   CD_ESTADO                   object
10  CD_REF_BACEN_INVESTIMENTO   float64
11  CD_TIPO_SEGURO              int64
12  CD_EMPREENDIMENTO           int64
13  CD_PROGRAMA                 int64
14  CD_TIPO_ENCARG_FINANC       int64
15  CD_TIPO_IRRIGACAO           int64
16  CD_TIPO_AGRICULTURA         int64
17  CD_FASE_CICLO_PRODUCAO      int64
18  CD_TIPO_CULTIVO             int64
19  CD_TIPO_INTGR_CONSOR        int64
20  CD_TIPO_GRAO_SEMENTE        int64
21  VL_ALIQ_PROAGRO             float64
22  VL_JUROS                    float64
23  VL_PRESTACAO_INVESTIMENTO   float64
24  VL_PREV_PROD                float64
25  VL_QUANTIDADE               float64
26  VL_RECEITA_BRUTA_ESPERADA   float64
27  VL_PARC_CREDITO             float64
28  VL_REC_PROPRIO              float64
29  VL_PERC_RISCO_STN           float64
30  VL_PERC_RISCO_FUNDO_CONST   float64
31  VL_REC_PROPRIO_SRV          float64
32  VL_AREA_FINANC              float64
33  CD_SUBPROGRAMA              float64
34  VL_PRODUTIV_OBTIDA          float64
35  DT_FIM_COLHEITA             object
36  DT_FIM_PLANTIO              object
37  DT_INIC_COLHEITA            object
38  DT_INIC_PLANTIO             object
39  VL_JUROS_ENC_FINAN_POSFIX   float64
40  VL_PERC_CUSTO_EFET_TOTAL    float64
41  CD_CONTRATO_STN             float64
42  CD_CNPJ_CADASTRANTE         float64
43  VL_AREA_INFORMADA           float64
44  CD_CICLO_CULTIVAR           float64
45  CD_TIPO_SOLO                float64
46  PC_BONUS_CAR                float64
47  #LIR_DT_LIBERACAO           object
48  LIR_VL_LIBERADO             float64
49  FINALIDADE                  object
50  ATIVIDADE                   object
51  MODALIDADE                  object
52  PRODUTO                     object
53  VARIEDADE                   object
54  DESCRICAO_FONTES            object
55  DESCRICAO_PROGRAMA          object
56  DESCRICAO_SUBPROGRAMA       object
```

```
 57  DESCRICAO_AGRO             object
 58  DESCRICAO_CULTIVO          object
 59  DESCRICAO_INTEGRACAO       object
dtypes: float64(25), int64(16), object(19)
memory usage: 1.1+ GB
```

3 Definindo variáveis chave e olhando correlação e distribuição

Os dados dessa tabela possuem 60 variáveis que podem ser utilizadas, sendo que a maioria delas é categórica. Selecionamos as seguintes variáveis quantitativas para usar na regressão:

1. Valor da Parcela
2. Área Financiada
3. Receita Bruta Esperada
4. Taxa de Juros
5. Quantidade Produzida
6. Recurso Próprio

[5]:
```
# selecionando as variáveis e mostrando as correlações

df2 = df[['VL_AREA_FINANC',
          'VL_RECEITA_BRUTA_ESPERADA',
          'VL_PARC_CREDITO',
          'VL_JUROS',
          'VL_QUANTIDADE',
          'VL_REC_PROPRIO_SRV']]

df2 = df2.dropna()

df2.shape
```

[5]:
```
(1487, 6)
```

[6]:
```
# sobram apenas 1487 observações se tirar os Nas

sns.heatmap(df2.corr(), annot = True, fmt = '.2f')
```

[6]:
```
<Axes: >
```

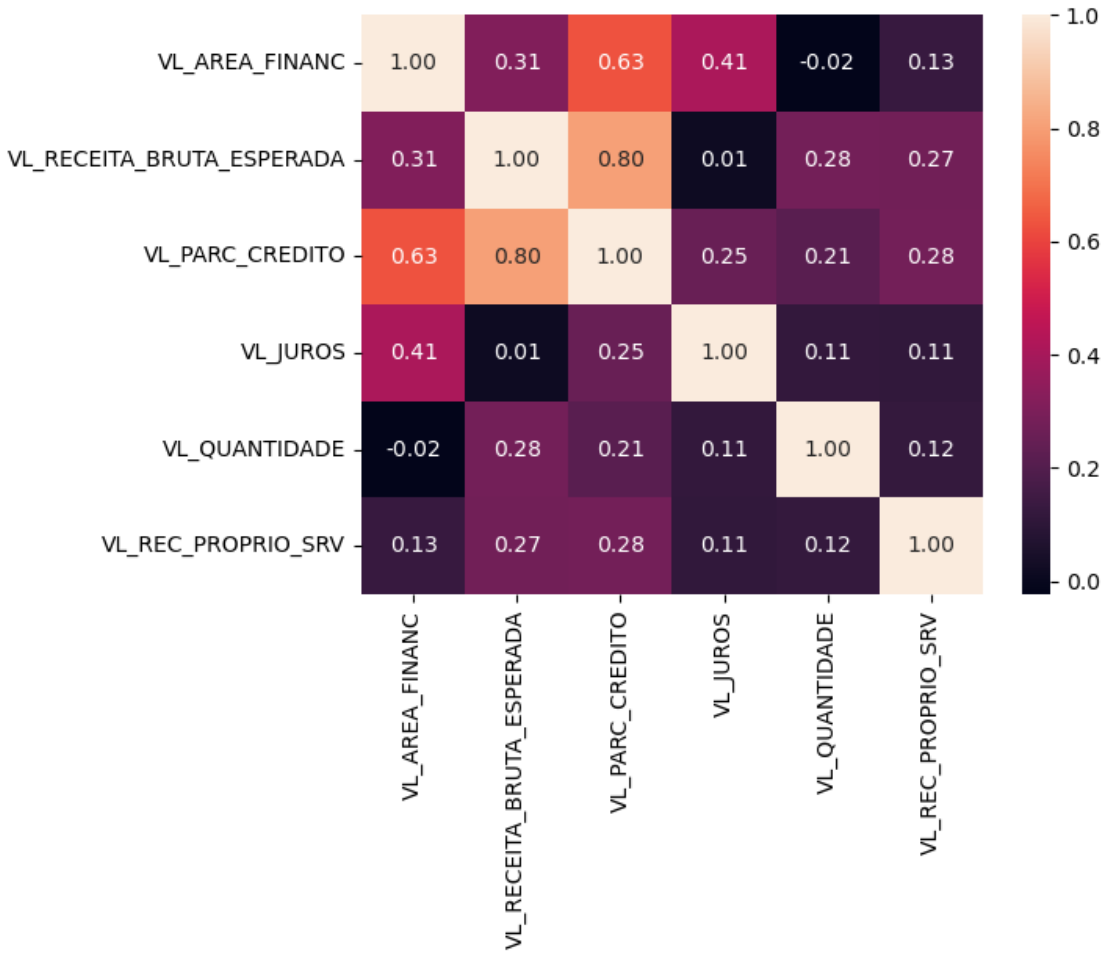

[7]:
```
# mostrando os histogramas das variáveis

xs = ['VL_AREA_FINANC',
      'VL_RECEITA_BRUTA_ESPERADA',
      'VL_QUANTIDADE',
      'VL_REC_PROPRIO_SRV',
      'VL_JUROS']

y = 'VL_PARC_CREDITO'

fig, axes = plt.subplots(3, 2, figsize = (12,12), dpi = 720, sharey = True)

axes = axes.flatten()

for i, x in enumerate(xs):
```

```
    sns.histplot(data = df2, x = x, ax = axes[i], bins = 20, kde = True, color␣
 ↪= 'red')

axes[-1].axis('off')
plt.show()
```

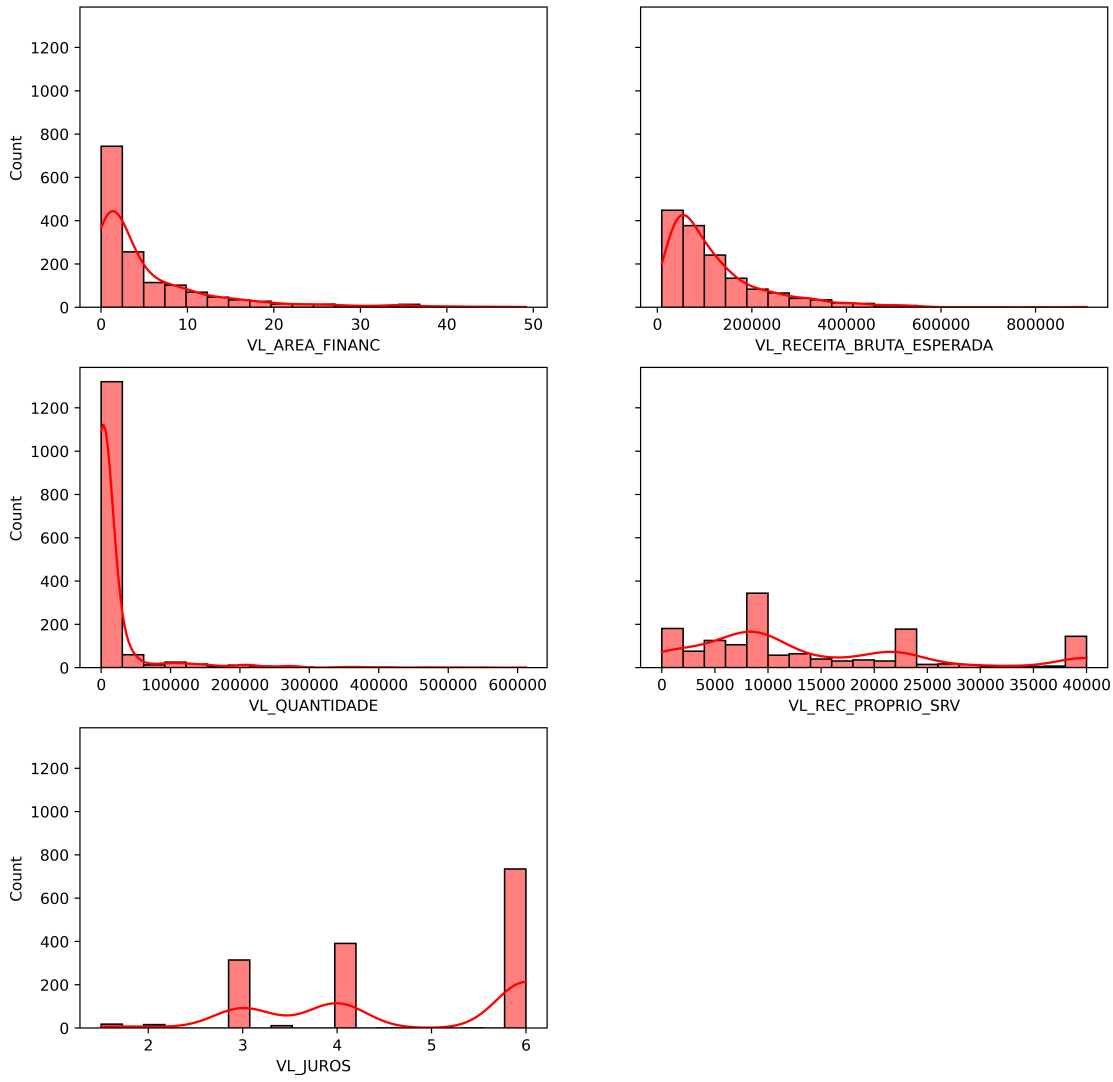

[8]:
```
# olhando as variáveis comparando com a variável a ser explicada

xs = ['VL_AREA_FINANC',
      'VL_RECEITA_BRUTA_ESPERADA',
      'VL_QUANTIDADE',
      'VL_REC_PROPRIO_SRV',
      'VL_JUROS']
```

```
y = 'VL_PARC_CREDITO'

# df3 = np.log(df2 + 1)

fig, axes = plt.subplots(3,2, figsize = (12,12), dpi = 720, sharey = True)

axes = axes.flatten()

for i, x in enumerate(xs):

    sns.scatterplot(data = df2 ,x = x, y = y, ax = axes[i], color = 'Teal')

axes[-1].axis('off')

plt.show()
```

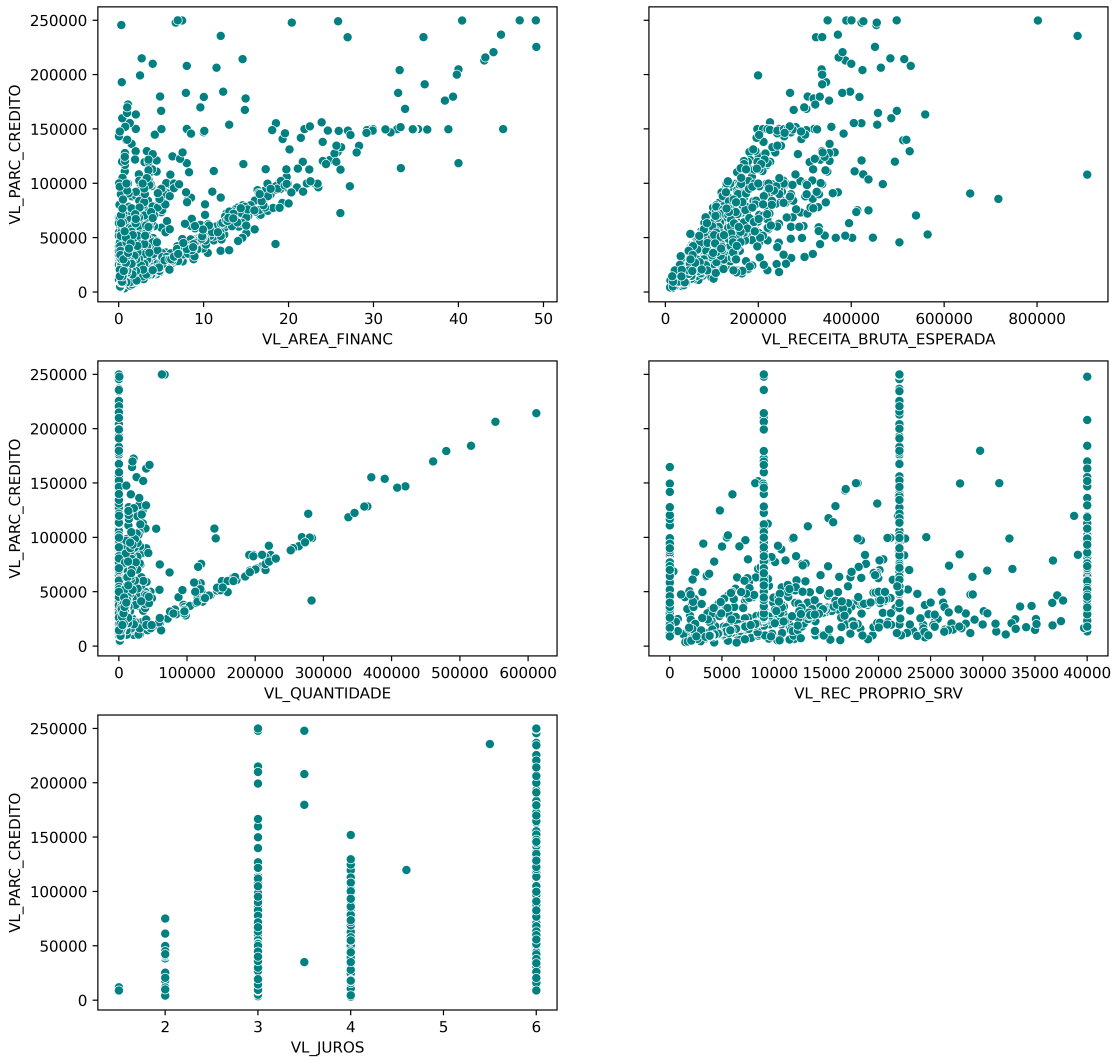

4 Detectando e removendo outliers

Para remoção de pontos extremos foram aplicadas as técnicas apresentadas no livro An Introduction to Statistical Learning. Para os outliers, foi calculado o resíduo dividido pelo desvio padrão estimado (resíduos de student) e para as variáveis explicativas foi calculada a alavancagem desses pontos.

[9]:
```
# Definindo as variáveis

Y = df2['VL_PARC_CREDITO']

X = df2[['VL_AREA_FINANC',
         'VL_RECEITA_BRUTA_ESPERADA',
         'VL_QUANTIDADE',
         'VL_REC_PROPRIO_SRV',
         'VL_JUROS']]

X = sm.add_constant(X)
```

[10]:
```
# Estimando o modelo para depois detectar os outliers e pontos de alta␣
 ↪alavancagem

model = sm.OLS(Y,X)

model = model.fit()

influencia = model.get_influence()
```

[11]:
```
# encontrando os outliers

df2[influencia.resid_studentized < 2].head()
```

[11]:

	VL_AREA_FINANC	VL_RECEITA_BRUTA_ESPERADA	VL_PARC_CREDITO	VL_JUROS	\
1906	0.29	28731.75	7754.33	4.0	
2989	0.06	100278.00	17181.03	6.0	
5229	0.90	59899.50	20936.07	4.0	
5813	1.49	200880.00	45240.96	4.0	
6709	1.00	63855.00	30669.98	4.0	

	VL_QUANTIDADE	VL_REC_PROPRIO_SRV
1906	2175.0	15231.07
2989	16200.0	0.00
5229	4050.0	26983.53
5813	13500.0	0.00
6709	5500.0	20414.02

[12]:
```
# Encontrando os pontos de alta alavancagem

leverage = influencia.hat_matrix_diag
limite = 2*X.shape[1]/X.shape[0]
df2[leverage < limite].head()
```

[12]:

	VL_AREA_FINANC	VL_RECEITA_BRUTA_ESPERADA	VL_PARC_CREDITO	VL_JUROS	\
1906	0.29	28731.75	7754.33	4.0	
2989	0.06	100278.00	17181.03	6.0	
5229	0.90	59899.50	20936.07	4.0	
5813	1.49	200880.00	45240.96	4.0	
6709	1.00	63855.00	30669.98	4.0	

	VL_QUANTIDADE	VL_REC_PROPRIO_SRV
1906	2175.0	15231.07
2989	16200.0	0.00
5229	4050.0	26983.53
5813	13500.0	0.00
6709	5500.0	20414.02

5 Resultados do primeiro modelo

[13]:
```
#### estimando o novo modelo

# definindo o dataframe

df3 = df2[(leverage < limite) | (influencia.resid_studentized < 2)]

df3.shape
```

[13]: (1474, 6)

[14]:
```
# definindo as variáveis

Y = df3['VL_PARC_CREDITO']

X = df3[['VL_AREA_FINANC',
         'VL_RECEITA_BRUTA_ESPERADA',
         'VL_QUANTIDADE',
         'VL_REC_PROPRIO_SRV',
         'VL_JUROS']]

X = sm.add_constant(X)

# estimando o modelo

model = sm.OLS(Y,X)
```

[14]:
```
model = model.fit(cov_type = 'HC1')

model.summary()
```

Dep. Variable:	VL_PARC_CREDITO	**R-squared:**	0.817
Model:	OLS	**Adj. R-squared:**	0.817
Method:	Least Squares	**F-statistic:**	1198.
Date:	Mon, 23 Jun 2025	**Prob (F-statistic):**	0.00
Time:	10:06:30	**Log-Likelihood:**	-16549.
No. Observations:	1474	**AIC:**	3.311e+04
Df Residuals:	1468	**BIC:**	3.314e+04
Df Model:	5		
Covariance Type:	HC1		

	coef	**std err**	**z**	**P> |z|**	**[0.025**	**0.975]**
const	-7283.9086	2037.307	-3.575	0.000	-1.13e+04	-3290.861
VL_AREA_FINANC	2277.1065	98.964	23.009	0.000	2083.140	2471.073
VL_RECEITA_BRUTA_ESPERADA	0.2549	0.015	16.923	0.000	0.225	0.284
VL_QUANTIDADE	0.0318	0.012	2.746	0.006	0.009	0.054
VL_REC_PROPRIO_SRV	0.1228	0.055	2.222	0.026	0.014	0.231
VL_JUROS	2885.4042	426.889	6.759	0.000	2048.717	3722.091

Omnibus:	304.743	**Durbin-Watson:**	1.712
Prob(Omnibus):	0.000	**Jarque-Bera (JB):**	8272.215
Skew:	0.237	**Prob(JB):**	0.00
Kurtosis:	14.596	**Cond. No.**	6.80e+05

Notes:
[1] Standard Errors are heteroscedasticity robust (HC1)
[2] The condition number is large, 6.8e+05. This might indicate that there are strong multicollinearity or other numerical problems.

O teste de Jarque-Bera possui valor muito elevado, o que indica que os resíduos não seguem uma distribuição normal. Portanto, a interpretação dos coeficientes obtidos deve ser limitada. Além disso, o teste de Breusch-Pagan indica que também há heteroscedasticidade no erro da regressão.

[15]:
```
from statsmodels.stats.diagnostic import het_breuschpagan

residuals = model.resid
exog = model.model.exog

bp_test = het_breuschpagan(residuals, exog)

labels = ['LM statistic','LM p-value', 'F statistic','F p-value']

dict(zip(labels, bp_test))
```

[15]:
```
{'LM statistic': 438.51052813251,
 'LM p-value': 1.4770843109521041e-92,
 'F statistic': 124.33413816126217,
 'F p-value': 6.731520350979224e-110}
```

6 Testando um modelo com apenas a Receita Bruta Esperada

[16]:
```
df2 = df[['VL_PARC_CREDITO','VL_RECEITA_BRUTA_ESPERADA']]
df2 = df2.dropna()
X = np.log(df2['VL_RECEITA_BRUTA_ESPERADA'] + 1)
X = sm.add_constant(X)
Y = np.log(df2['VL_PARC_CREDITO'] + 1)
model = sm.OLS(Y,X)
model = model.fit()
influencia = model.get_influence()
leverage = influencia.hat_matrix_diag
limite = 2*X.shape[1]/X.shape[0]
df2 = df2[(leverage < limite) | (influencia.resid_studentized < 2)]
```

[17]:
```
X = np.log(df2['VL_RECEITA_BRUTA_ESPERADA'] + 1)

X = sm.add_constant(X)

Y = np.log(df2['VL_PARC_CREDITO'] + 1)

sns.scatterplot(y = Y, x = X.iloc[:,1])
plt.show()
```

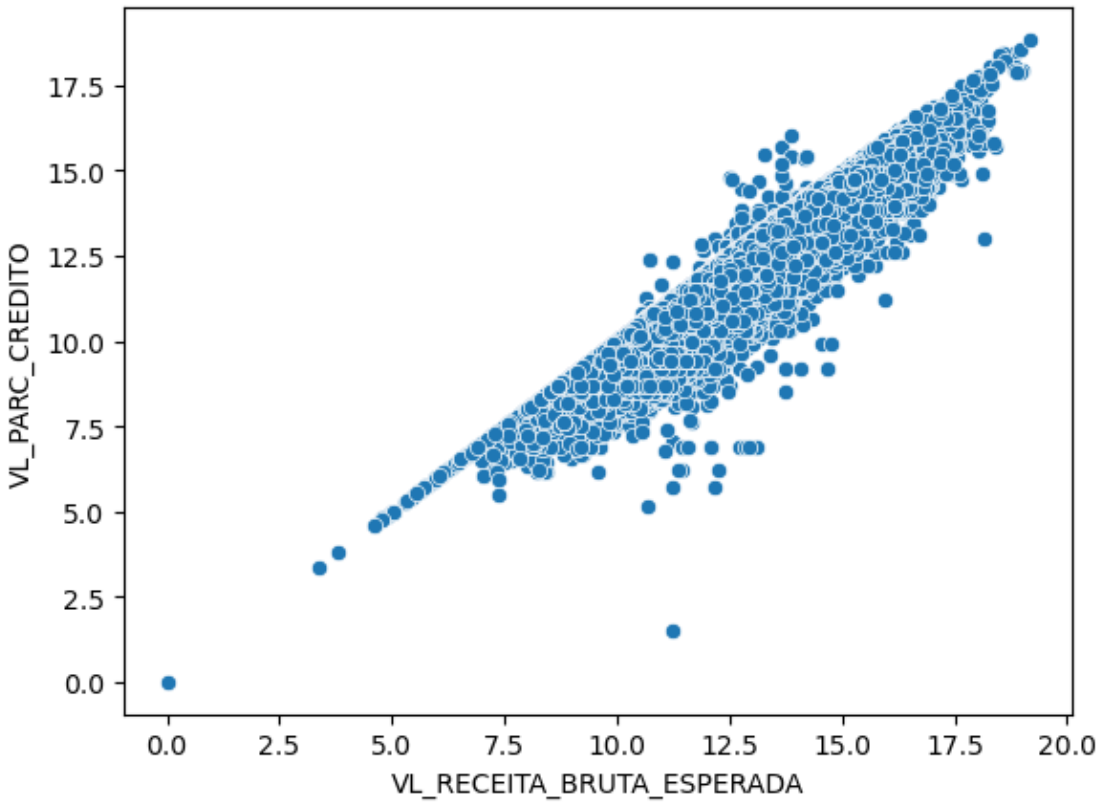

[18]:
```
model = sm.OLS(Y,X)

model = model.fit()

model.summary()
```

[18]:

Dep. Variable:	VL_PARC_CREDITO	**R-squared:**	0.920
Model:	OLS	**Adj. R-squared:**	0.920
Method:	Least Squares	**F-statistic:**	1.264e+07
Date:	Mon, 23 Jun 2025	**Prob (F-statistic):**	0.00
Time:	10:06:38	**Log-Likelihood:**	-5.1693e+05
No. Observations:	1095297	**AIC:**	1.034e+06
Df Residuals:	1095295	**BIC:**	1.034e+06
Df Model:	1		
Covariance Type:	nonrobust		

	coef	**std err**	**t**	**P> |t|**	**[0.025**	**0.975]**
const	-0.2897	0.003	-89.202	0.000	-0.296	-0.283
VL_RECEITA_BRUTA_ESPERADA	0.9662	0.000	3555.366	0.000	0.966	0.967

Omnibus:	323323.159	**Durbin-Watson:**	1.699
Prob(Omnibus):	0.000	**Jarque-Bera (JB):**	1125782.861
Skew:	-1.478	**Prob(JB):**	0.00
Kurtosis:	6.992	**Cond. No.**	105.

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Uma regressão usando apenas o logaritmo da receita esperada oferece um bom resultado